Metody Probabilistyczne i Statystyka

Zadanie domowe 3

Michał Łukomski

255552

```
begin
# biblioteki używane w tym ćwiczeniu
using Random
using SHA
using Plots
using StatsPlots
using Distributions
using LaTeXStrings
using StableRNGs
using PlutoUI
end
```

Zad 1 - testy NIST

```
bits_length = 10000000

• bits_length = 10_000_000

seed = 21

• seed = 21 # for reproducibility, note that RandomDevice, always produce different results
```

To see the output, uncomment #|> println

linear congruential generator (LCG)

```
rand(StableRNG(seed), Bool, bits_length) .|>
UInt8 .|> string |> join #|> println
```

MersenneTwister - requires much more space to store the state ector and generate a random sequence than Xoshiro256++

```
rand(MersenneTwister(seed), Bool, bits_length) .|>
UInt8 .|> string |> join # |> println
```

Xoshiro256++ - default Julia algorithm

```
rand(Xoshiro(seed), Bool, bits_length) .|>
UInt8 .|> string |> join # |> println
```

RandomDevice - Entropy obtained from the operating system - the only cryptographically secure random number generator from the ones tested, always produce different results

```
rand(RandomDevice(), Bool, bits_length) .|>
UInt8 .|> string |> join #|> println
```

Output zwrócony przez funkcję hashującą SHA-1 dla własnego nazwiska

```
• sha1("Łukomski") .|> bitstring |> join |> println
```

Wyniki testów NIST zostały przedstawione w poniższej tabeli, dokładne zrzuty ekranu z otrzymanymi **p**-value znajdują się na końcu dokumentu. Generatory testowano na sekwencji 10 milionów bitów każdy. Z testowanych generatorów trzy, tj. LCG, Xoshiro oraz fizyczny rng komputera, przeszły wszystkie testy, a MersenneTwister przeszedł prawie wszystkie testy, poza *Random Excursion Test*. Output funkcji SHA-1 dla nazwiska autora - "Łukomski" - był za krótki dla 8 z 14 testów, jednak przeszedł pomyślnie wszystkie testy dla których miał odpowiednią długość.

100				
LCG	MersnneTwister	Xoshiro	RandomDevice	SHA ₁
Passed	Passed	Passed	Passed	Passed
Passed	Passed	Passed	Passed	Passed
Passed	Passed	Passed	Passed	Passed
Passed	Passed	Passed	Passed	Passed
Passed	Passed	Passed	Passed	
Passed	Passed	Passed	Passed	
Passed	Passed	Passed	Passed	
Passed	Passed	Passed	Passed	
Passed	Passed	Passed	Passed	
Passed	Passed	Passed	Passed	
Passed	Passed	Passed	Passed	Passed
Passed	Passed	Passed	Passed	Passed
Passed	Failed	Passed	Passed	
Passed	Passed	Passed	Passed	
FFFFFFF	Passed	Passed	Passed	Passed

Wnioskuje się więc, że wszystkie badane generatory liczb pseudolosowych mają poprawne właściwości i z powodzeniem przybliżają losowanie liczb losowych. Do kryptograficznych zastosowań jednak, zaleca się używanie jedynie RandomDevice. Należy wziąć pod uwagę też, że testy te były przeprowadzane tylko dla jednego ziarna (seed=21 w tym przypadku) i mogą się różnić dla innych ziaren, co przy dokładniejszym badaniu generatorów trzeba by wziąć pod uwagę i zbadać wyniki dla wielu ziaren.

Zad 2 - Błądzenie losowe na liczbach całkowitych

Zmienna losowa $S_N=\sum_{n=1}^N X_n$, gdzie X_n są niezależne i każda przyjmuje wartości 1 oraz -1 z prawdopodobieństwem 0.5. Dla N=0 przyjmuje się $S_0=0$.

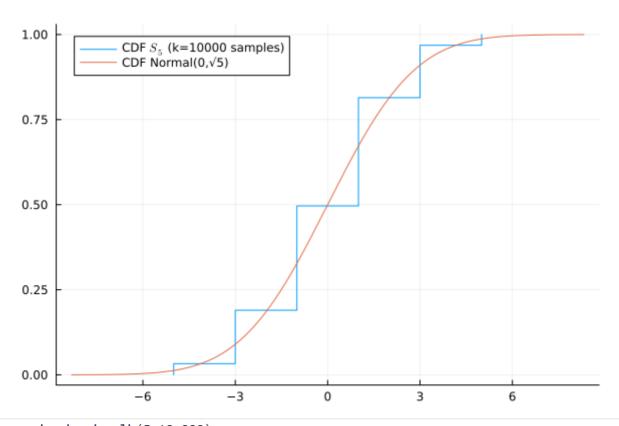
```
S (generic function with 1 method)
```

```
• S(N) = rand([-1,1], N) | > sum
```

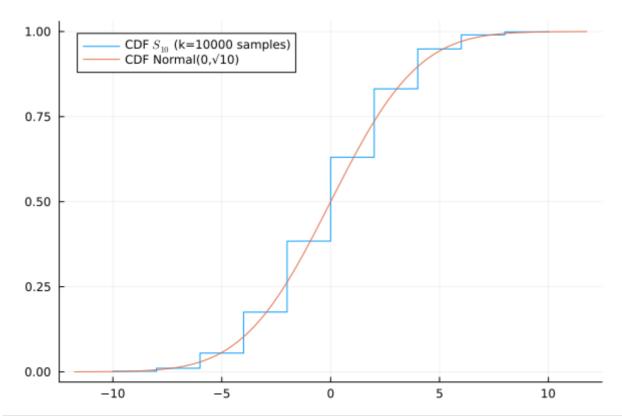
drunkard_walk (generic function with 1 method)

```
    function drunkard_walk(N,k)
    res = [S(N) for _ in 1:k]
    fig = plot(sort(res), (1:k)./k, label=L"CDF $S_{%$N}$ (k=%$k samples)")
    plot!(fig, Normal(0,√N), func=cdf, label="CDF Normal(0,√$N)")
    return fig
    end
```

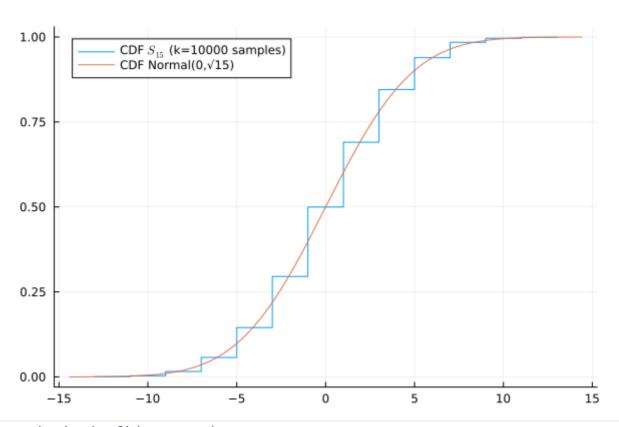
Poniżej przedstawiono wykresy dystrybuanty zmiennej losowej S_N dla $N\in\{5,10,15,20,25,30,100\}$ oraz rozkładu normalnego $\mathcal{N}(\mu=0,\sigma=\sqrt{N})$, który miałyby aproksymować S_N .



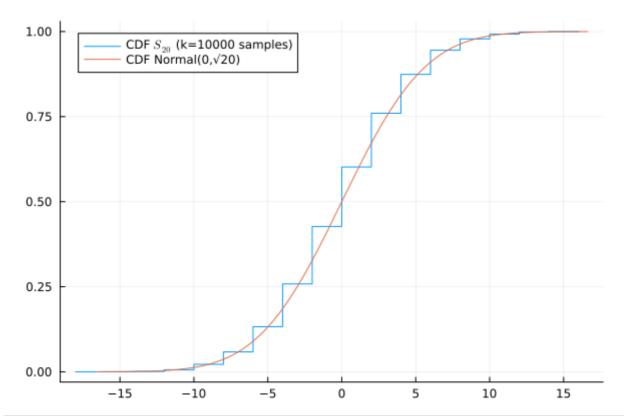
drunkard_walk(5,10_000)



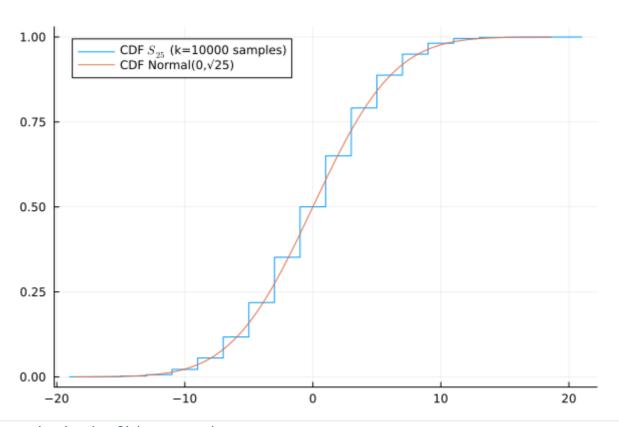
drunkard_walk(10,10_000)



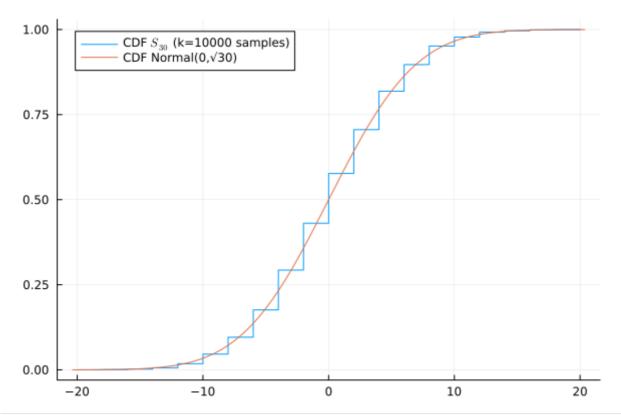
- drunkard_walk(15,10_000)



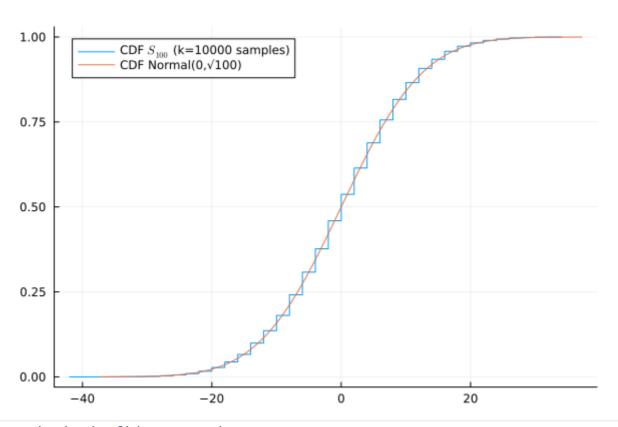
drunkard_walk(20,10_000)



drunkard_walk(25,10_000)



drunkard_walk(30,10_000)



drunkard_walk(100,10_000)

Można zauważyć, że im większe N, tym bardziej S_N zbliża się do rozkładu normalnego, aczkolwiek nie będą one nigdy sobie równe z uwagi na fakt, że rozkład normalny jest rozkładem ciąłym, a S_N dyskretnym.

Wynika z tego fakt, że dysponując jedynie generatorem losowych, pojedynczych bitów, możeby w przybliżeniu otrzymać generator liczb z rozkładu normalnego - wystarczy generować wystarczająco długi ciąg bitów (wystarczająco duże N), tak aby otrzymać satysfakcjonujące nas przybliżenie, a później przeskalować wynik na docelową średnią i wariancję.

Zad 3 Błądzenie losowe na liczbach całkowitych - rozkład czasu nad osiąOX

 P_N odpowiada "frakcji czasu" jaki rozważany proces (S_N) "spęda nad osią OX".

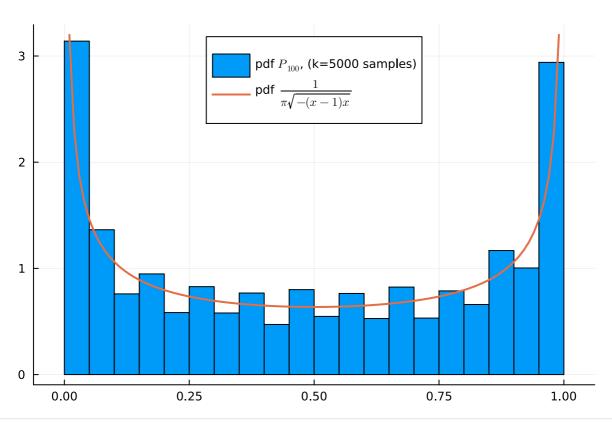
frac_over_OX (generic function with 2 methods)

```
function frac_over_OX(N,k, nbins=20)
     SN = hcat(zeros(k,1), rand([-1,1], (k,N)))
     cumSN = cumsum(SN, dims=2)
     D_n = reduce(hcat,[cumSN[:,i].>0.] cumSN[:,i-1].>0 for i in 2:(N+1)]) # S_0 =
     P_N = sum(D_n, dims=2) / N
     # przedziały są [a,b), więc bez nextfloat, 1.0 zostają ucinane
     plt = histogram(
         P_N,
         bins=range(0, nextfloat(1.0), length=nbins+1), # +1, because its the edges
         normalize=:pdf,
         label=L"pdf $P_{%$N}$, (k=5000 samples)",
         legend=:top
     plot!(plt, 0:0.01:1, x \rightarrow 1/(\pi * sqrt(-(x-1)*x)),
         linewidth=2)
     return plt
 end
```

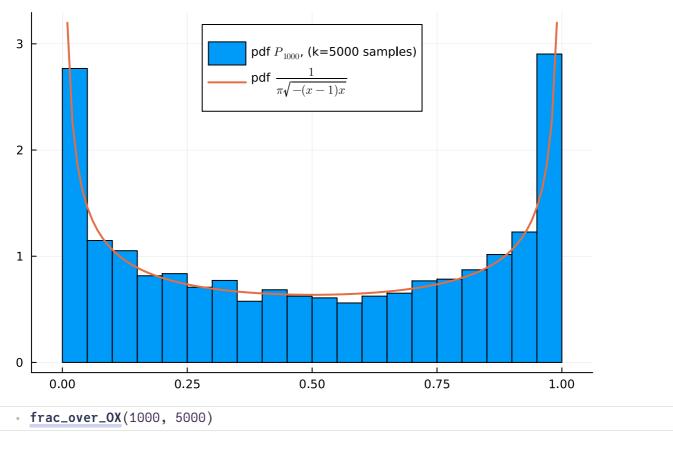
Poniżej przedstawiono unormowane wykresy aproksymowanej funkcji gęstośći prawdopodobieństwa P_N dla $N \in \{100, 1000, 10000\}$. Na wykres naniesiono też wykres gęstośći rozkłądu arcusa sinusa o dokładnym wzorze

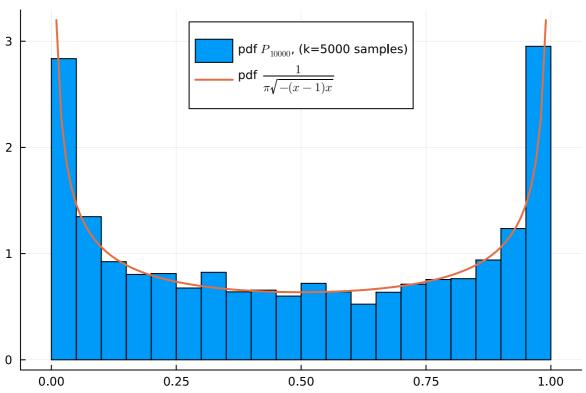
$$rac{d}{dx}rac{2}{\pi} rcsin(\sqrt{x}) = rac{1}{\pi\sqrt{-(x-1)x}}.$$

.



frac_over_OX(100, 5000)





Rozkłady P_N całkiem dobrze estymują gęstość prawdopodobieństwa arcusa sinusa, a im większe N tym lepsza ta aproksymacja.

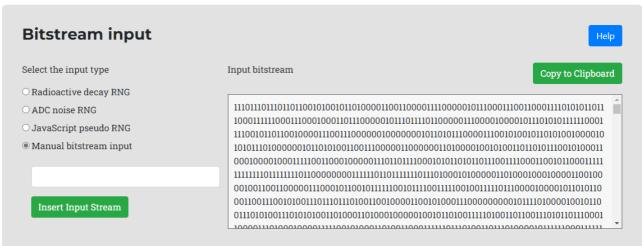
frac_over_OX(10_000, 5000)

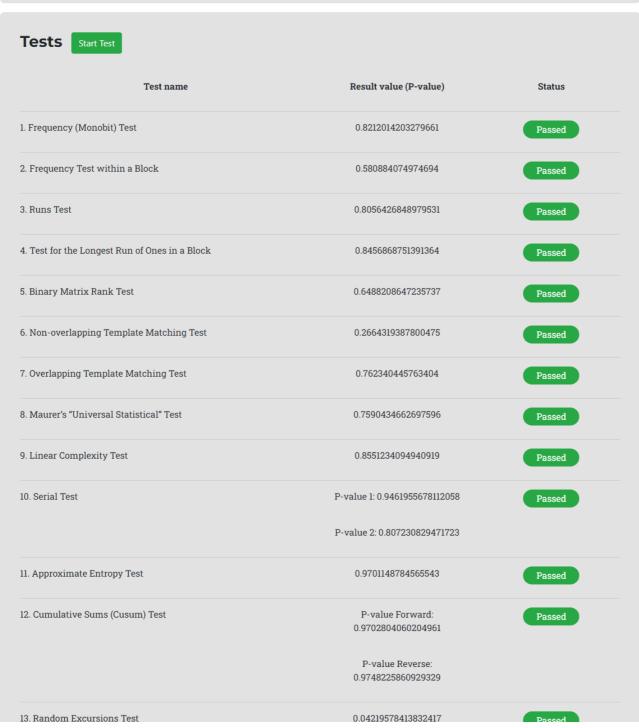
Fakt, że co drugi przedział ma większą gęstość na histogramie pdf P_{100} można wytłumaczyć skończoną liczbą wartości jakie może przyjąć $P_{100} \in \{0, 0.02, 0.04, 0.06, 0.08, 0.1, \ldots\}$ (jak pijak wejdzie nad oś OX to musi wykonać tyle samo kroków, żeby zejść pod OX, więc przebywa tam parzystą ilość czasu). Jeśli przedział [0,1] podzielimy na 20 kubełków, każdy o szerokości 0.05, to każdy z nich może przyjmować dwie (0.2,0.4), lub trzy (0.6,0.8,0.0) z dozwolonych wartości P_{100} (mogłoby też być odwotnie, w zależności od tego gdzie wpadłyby próbki z zerową częścią setną (0.0)). Na kolejnych wykresach, tj P_{1000} oraz P_{10000} gęstość może przyjmować wielkośći, stąd bias związany z większymi gęstościami co drugiego kubełka znika.

Podobnie jak w zadaniu 2, tutaj też nasuwa się wniosek, że mając do dyspozycji jedynie generator losowych, pojedynczych bitów, można wylosować zmienną z rozkładu arcusa sinusa - wystarczy wybrać dostatecznie duże N, aby otrzymać satysfakcjonujące nas przybliżenie.

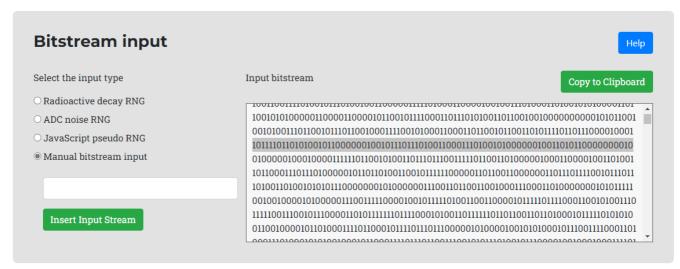
Screenshots from taken NIST tests

LCG





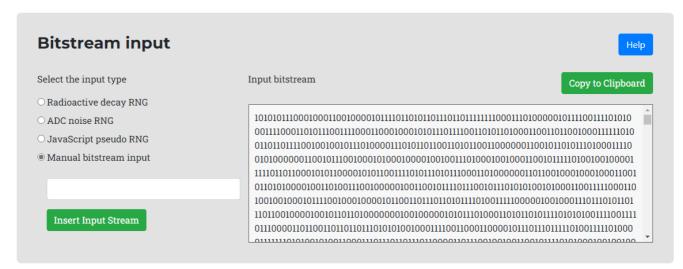
MersenneTwister

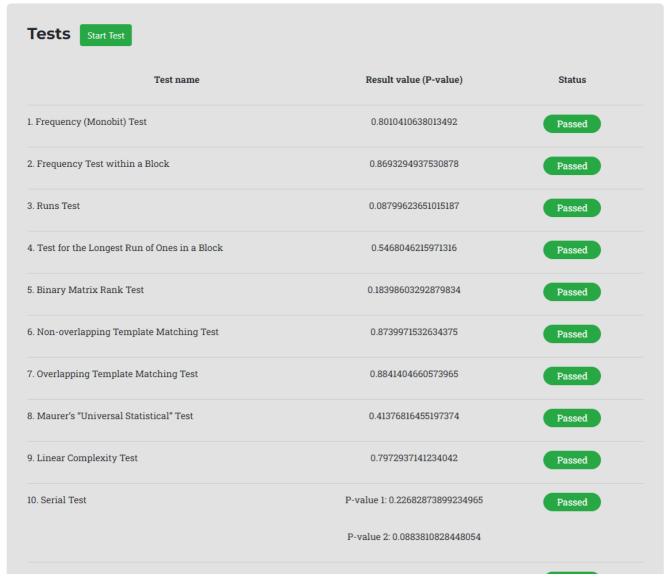


Tests Start Test		
Test name	Result value (P-value)	Status
1. Frequency (Monobit) Test	0.14048159116628955	Passed
2. Frequency Test within a Block	0.7892072199878524	Passed
3. Runs Test	0.3279878771437552	Passed
4. Test for the Longest Run of Ones in a Block	0.1541131216153005	Passed
5. Binary Matrix Rank Test	0.7026539174670077	Passed
6. Non-overlapping Template Matching Test	0.6522536157854708	Passed
7. Overlapping Template Matching Test	0.35288882418532314	Passed
8. Maurer's "Universal Statistical" Test	0.5413271647888743	Passed
9. Linear Complexity Test	0.38817731391419175	Passed
10. Serial Test	P-value 1: 0.20958497778645147	Passed
	P-value 2: 0.329064497695741	
11. Approximate Entropy Test	0.22779360351574873	Passed
12. Cumulative Sums (Cusum) Test	P-value Forward: 0.16196940795730996	Passed

	P-value Reverse: 0.2062009772408051	
13. Random Excursions Test	0.0013245977419050652 Failed	
14. Random Excursions Variant Test	0.10886671847679363 Passed	

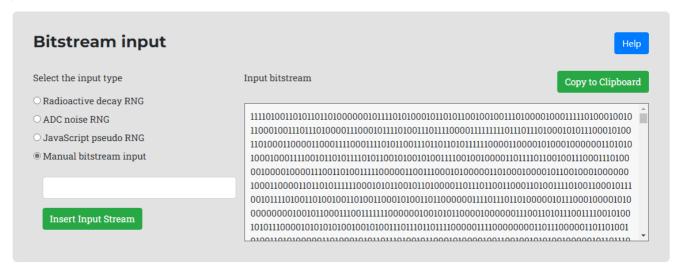
Xoshiro

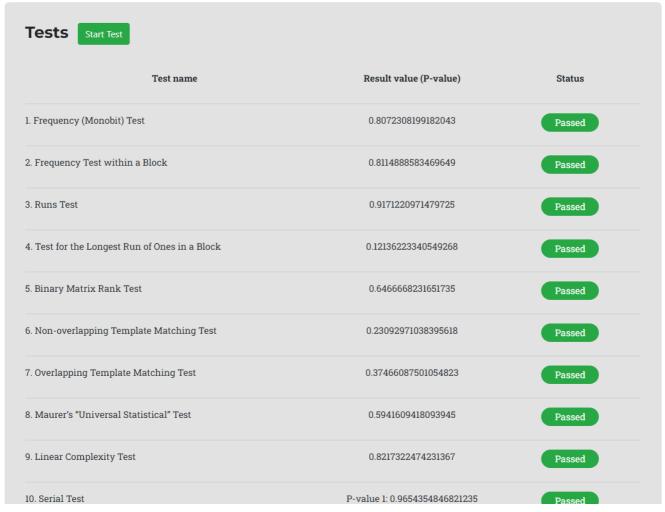




11. Approximate Entropy Test	0.32450735506808553	Passed
12. Cumulative Sums (Cusum) Test	P-value Forward: 0.9864780361603191	Passed
	P-value Reverse: 0.8384767416833223	
13. Random Excursions Test	0.16822139183673288	Passed
14. Random Excursions Variant Test	0.05369118778739712	Passed

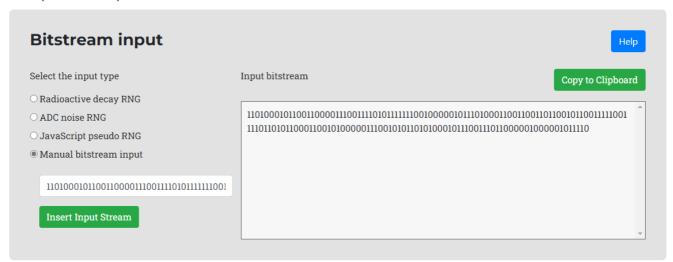
RandomDevice

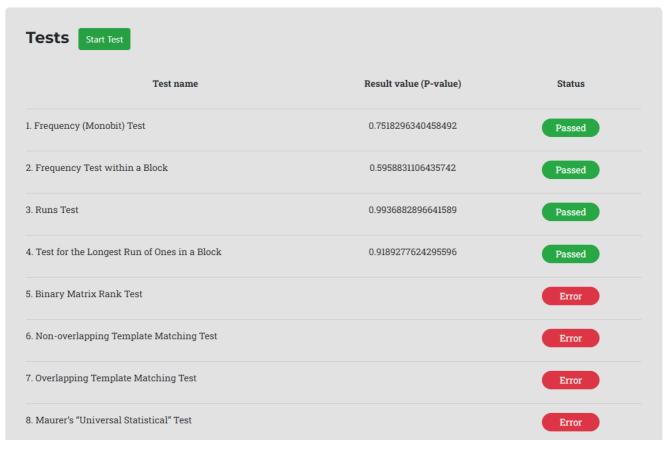




	P-value 2: 0.9171693529296843		
11. Approximate Entropy Test	0.9954073255066652	Passed	
12. Cumulative Sums (Cusum) Test	P-value Forward: 0.9698890909141935	Passed	
	P-value Reverse: 0.9670638355076171		
13. Random Excursions Test	0.13963861323948124	Passed	
14. Random Excursions Variant Test	0.12327675871463906	Passed	

SHA1("Łukomski")





9. Linear Complexity Test		Error
10. Serial Test		Error
II. Approximate Entropy Test	0.8458881903464261	Passed
12. Cumulative Sums (Cusum) Test	P-value Forward: 0.6767145733894937	Passed
	P-value Reverse: 0.9708655536252708	
13. Random Excursions Test		Error
14. Random Excursions Variant Test		Error